



Il tuo partner per la Formazione e la Trasformazione digitale della tua azienda



Note			



SPRING AI

GENERATIVE ARTIFICIAL INTELLIGENCE CON JAVA

Simone Scannapieco

Corso avanzato per Venis S.p.A, Venezia, Italia

Novembre 2025

Note		



PROGETTO SPRING AI



- Inizializzare un progetto Spring con le seguenti caratteristiche:
 - Maven come build tool
 - Spring Boot alla versione più recente non SNAPSHOT
 - Linguaggio Java 21
 - Group it.venis.ai.spring
 - Artifact demo
 - jar packaging
 - Spring Web, OpenAI o Ollama come dipendenze
- A Riportare variabili di ambiente env in launch. json e settings. json

Note		

PROGETTO SPRING AI APPLICAZIONE E PASSAGGI



- Stub di progetto Spring Al multi-configurazione (Gemini + Ollama)
 - 1 Creazione docker-compose.yml per servizio Docker Ollama
 - 2 Creazione file variabili di ambiente per servizio Ollama
 - 3 Creazione script per start, stop ed eliminazione servizi Docker
 - Creazione configurazione multi-LLM
 - Creazione modelli per domanda e risposta
 - 6 Creazione interfaccia ed implementazione del servizio di richiesta
 - Creazione del controllore MVC
 - 8 Test delle funzionalità con Postman/Insomnia

Note		

PROGETTO SPRING AI SERVIZIO DOCKER OLLAMA - I

Simone Scannapieco

Note



m Venis S.p.A, Venezia, IT

5/16

File docker-compose.yml spring-ai-llm-gpu: image: ollama/ollama:\${OLLAMA_VERSION:-latest} $\verb|hostname: spring-ai-llm| \\$ container_name: spring_ai_llm environment: OLLAMA_HOST: "\${OLLAMA_HOST:-0.0.0.0}:\${OLLAMA_PORT-11434}" OLLAMA_DEBUG: \${OLLAMA_DEBUG:-false} OLLAMA_FLASH_ATTENTION: \${OLLAMA_FLASH_ATTENTION:-false} OLLAMA_KEEP_ALIVE: \${OLLAMA_KEEP_ALIVE:-"5m"} OLLAMA_MAX_LOADED_MODELS: \${OLLAMA_MAX_LOADED_MODELS:-1} OLLAMA_NUM_PARALLEL: \${OLLAMA_NUM_PARALLEL:-1} expose: - \${OLLAMA_PORT:-11434} deploy: resources: reservations: devices: - driver: nvidia count: all capabilities: [gpu] - spring_ai_llm:/root/.ollama restart: unless-stopped profiles: [llm-gpu]

PROGETTO SPRING AI SERVIZIO DOCKER OLLAMA - II

Simone Scannapieco

Note



m Venis S.p.A, Venezia, IT €

6/16

```
File docker-compose.yml
  {\tt spring-ai-llm-cpu:}
    image: ollama/ollama:${OLLAMA_VERSION:-latest}
    hostname: spring-ai-llm
    container_name: spring_ai_llm
    environment:
     OLLAMA_HOST: "${OLLAMA_HOST:-0.0.0.0}:${OLLAMA_PORT-11434}"
      OLLAMA_DEBUG: ${OLLAMA_DEBUG:-false}
      OLLAMA_FLASH_ATTENTION: ${OLLAMA_FLASH_ATTENTION:-false}
      OLLAMA_KEEP_ALIVE: ${OLLAMA_KEEP_ALIVE:-"5m"}
OLLAMA_MAX_LOADED_MODELS: ${OLLAMA_MAX_LOADED_MODELS:-1}
      OLLAMA_NUM_PARALLEL: ${OLLAMA_NUM_PARALLEL:-1}
    expose:
      - ${OLLAMA_PORT:-11434}
    volumes:
      - spring_ai_llm:/root/.ollama
    restart: unless-stopped
    profiles: [llm-cpu]
volumes:
  spring_ai_llm:
    name: spring_ai_llm
```

PROGETTO SPRING AI VARIABILI DI AMBIENTE SERVIZIO DOCKER OLLAMA

Simone Scannapieco



7/16

File spring-ai.env # "llm-cpu" --> Large Language Model in cpu mode # "llm-gpu" --> Large Language Model in gpu mode MODE=11m-cpu COMPOSE_PROFILES=\${MODE} LOG_LEVEL=WARNING # default: WARNING # Ollama configuration #OLLAMA_VERSION=0.1.39 # default: latest OLLAMA_HOST=spring-ai-llm OLLAMA_PORT=11434 # default: 0.0.0.0 # default: 11434 # default: false # default: false OLLAMA_DEBUG=false OLLAMA_FLASH_ATTENTION=false OLLAMA_KEEP_ALIVE="5m" # default: "5m" OLLAMA_MAX_LOADED_MODELS=2 # default: 1 OLLAMA_NUM_PARALLEL=1 # default: 1 m Venis S.p.A, Venezia, IT

Note	

PROGETTO SPRING AI SCRIPT SERVIZI DOCKER



File start_spring_ai_services.sh

```
#!/bin/bash
stack=spring-ai-demo-services
rmi=local
file=docker-compose.yml
envfile=spring-ai.env

if [ -z ${1+x} ];
    then rmi=local;
    else rmi=$1;
fi

## --rmi flag must be one of: all, local
docker compose -f $file -p $stack --env-file $envfile up --build --remove-orphans --force-recreate --detach
```

Simone Scannapieco

Spring AI - Corso avanzato

m Venis S.p.A, Venezia, IT

8/16

PROGETTO SPRING AI SCRIPT SERVIZI DOCKER

Simone Scannapieco



m Venis S.p.A, Venezia, IT

9/16

File stop_spring_ai_services.sh #!/bin/bash stack=spring-ai-demo-services rmi=local file-docker-compose.yml envfile=spring-ai.env if [-z \${1+x}]; then rmi=local; else rmi=\$1; fi ## --rmi flag must be one of: all, local docker compose -f \$file -p \$stack --env-file \$envfile down --rmi \$rmi

Note		

PROGETTO SPRING AI SCRIPT SERVIZI DOCKER



File erase_spring_ai_services.sh

```
#!/bin/bash
stack=spring-ai-demo
rmi=local
file=docker-compose.yml
envfile=spring-ai.env

if [ -z ${1+x} ];
    then rmi=local;
    else rmi=$1;
fi

## --rmi flag must be one of: all, local
docker compose -f $file -p $stack --env-file $envfile down --rmi $rmi --volumes
```

Simone Scannapieco

Spring AI - Corso avanzato

m Venis S.p.A, Venezia, IT

10/16

PROGETTO SPRING AI CONFIGURAZIONE MULTI LLM





11/16

Configurazione Gemini + Ollama

```
package it.venis.ai.spring.demo.config;
         {\tt import org.springframework.ai.chat.client.ChatClient;}
         {\tt import org.springframework.ai.ollama.OllamaChatModel;}
         import org.springframework.ai.openai.OpenAiChatModel;
         import org.springframework.context.annotation.Bean;
         import org.springframework.context.annotation.Configuration;
         import org.springframework.context.annotation.Primary;
         @Configuration
         public class ChatClientConfig {
             public ChatClient openAiChatClient(OpenAiChatModel openaiChatModel) {
                return ChatClient.create(openaiChatModel);
                  * ChatClient.Builder chatClientBulder = ChatClient.builder(openaiChatModel);
                  * return chatClientBulder.build();
             }
             public ChatClient ollamaChatClient(OllamaChatModel ollamaChatModel) {
                 ChatClient.Builder chatClientBulder = ChatClient.builder(ollamaChatModel);
                 return chatClientBulder.build();
                  * return ChatClient.create(ollamaChatModel);
Simone Scannapieco
                                            Spring AI - Corso avanzato
                                                                                            m Venis S.p.A, Venezia, IT
```

N I		L _
INI	\mathbf{O}	ГΩ
IV	v	ᇈ

PROGETTO SPRING AI MODELLI PER DOMANDE E RISPOSTE



Modello per domanda

```
package it.venis.ai.spring.demo.model;
import java.util.UUID;
public record Question(UUID id, String question) {
    public Question(String question) {
        this(UUID.randomUUID(), question);
    }
}
```

Modello per risposta

```
package it.venis.ai.spring.demo.model;
public record Answer(String answer) {
}
```

Simone Scannapieco

Spring AI - Corso avanzato

m Venis S.p.A, Venezia, IT

12/16

PROGETTO SPRING AI SERVIZIO MULTI LLM





Interfaccia servizio package it.venis.ai.spring.demo.services; import it.venis.ai.spring.demo.model.Answer; ${\tt import it.venis.ai.spring.demo.model.Question;}$ public interface QuestionService { String getAnswer(String question); Answer getAnswer(Question question);

Simone Scannapieco

Spring AI - Corso avanzato

m Venis S.p.A, Venezia, IT

13/16

PROGETTO SPRING AI SERVIZIO MULTI LLM



14/16

Implementazione servizio

```
package it.venis.ai.spring.demo.services;
          import org.springframework.ai.chat.client.ChatClient;
import org.springframework.beans.factory.annotation.Qualifier;
          import org.springframework.context.annotation.Configuration;
          import org.springframework.stereotype.Service;
          import it.venis.ai.spring.demo.model.Answer;
import it.venis.ai.spring.demo.model.Question;
          @Service
          public class QuestionServiceImpl implements QuestionService {
              private final ChatClient chatClient;
              public QuestionServiceImpl(@Qualifier("ollamaChatClient") ChatClient chatClient) {
                   this.chatClient = chatClient;
              @Override
              public String getAnswer(String question) {
                  return this.chatClient.prompt()
                           .user(question)
                           .call()
                           .content();
              }
              public Answer getAnswer(Question question) {
                  return new Answer(getAnswer(question.question()));
Simone Scannapieco
                                                                                                       m Venis S.p.A, Venezia, IT
                                                 Spring AI - Corso avanzato
```

Note

PROGETTO SPRING AI MVC DEL SERVIZIO MULTI LLM



Implementazione controllore REST

```
package it.venis.ai.spring.demo.controllers;
import org.springframework.web.bind.annotation.PostMapping;
import org.springframework.web.bind.annotation.RequestBody;
import org.springframework.web.bind.annotation.RestController;
import it.venis.ai.spring.demo.model.Answer;
import it.venis.ai.spring.demo.model.Question;
import it.venis.ai.spring.demo.services.QuestionService;

@RestController
public class QuestionController {
    private final QuestionService service;
    public QuestionController(QuestionService service) {
        this.service = service;
    }

    @PostMapping("/client/ask")
    public Answer askQuestion(@RequestBody Question question) {
        return this.service.getAnswer(question);
    }
}
```

Simone Scannapieco

Spring AI - Corso avanzato

m Venis S.p.A, Venezia, IT

15/16



 $\label{lem:base-dgroove-venis-code.git} \textit{Branch: } 1-spring-ai-gemini-ollama-configuration$

Simone Scannapieco

Spring AI - Corso avanzato

m Venis S.p.A, Venezia, IT

16/16

Ν	ot	e
---	----	---