



Il tuo partner per la Formazione e la Trasformazione digitale della tua azienda



Note			



# **SPRING AI**

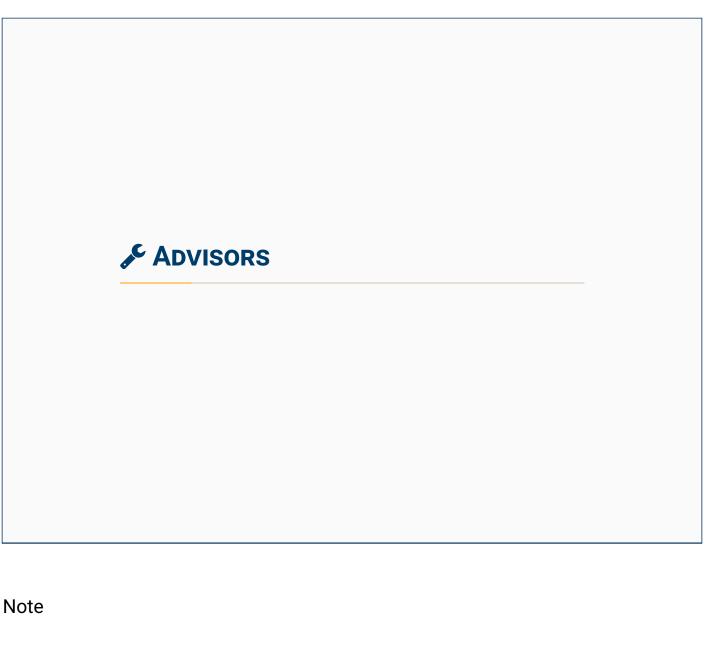
# GENERATIVE ARTIFICIAL INTELLIGENCE CON JAVA

# Simone Scannapieco

Corso avanzato per Venis S.p.A, Venezia, Italia

Novembre 2025

Note		



# SPRING AI ADVISORS DESCRIZIONE



- Entità in grado di intercettare
  - ♦ la request dal ChatClient al LLM
  - 1 la response del LLM prima che arrivi all'utente
- Utilizzi advisors
  - Pre-/post-processamento dei dati al/dal LLM
  - Validazione/filtraggio customizzato
  - Creare flussi di processamento puliti e sequenziali
    - A Possibile fornire una priorità
    - 🛕 Con ugual priorità, il sistema sceglie un ordinamento random
- Linee guida di buon utilizzo
  - Evitare comportamenti session-scoped
  - Creare più advisors in catena piuttosto che un unico advisor complesso
  - Evitare comportamenti che intacchino la logica del sistema (es. no modifiche al prompt)

Simone Scannapieco	■ Spring AI - Corso avanzato	m Venis S.p.A, Venezia, IT	3/13
Simone Scannapieco	Spring At - Corso avarizato	wellis S.p.A, vellezia, II	3/13

Note		

# **SPRING AI ADVISORS TIPOLOGIE**



- Advisors built-in
  - SimpleLoggerAdvisor riporta informazione dettagliata delle strutture di request e di response
  - SafeGuardAdvisor valida la request utente relativamente ad una blacklist
  - PromptChatMemoryAdvisor recupera e copia la memoria nel prompt come contesto di sistema
  - **()** ...
- Advisor utente
  - Devono implementare CallAdvisor e/o StreamAdvisor

# **Configurazione statica**

```
chatClientBuilder
   .defaultAdvisors(List.of(new SimpleLoggerAdvisor(1), new SafeGuardAdvisor(0)))
```

# Configurazione dinamica

```
chatClient
    .prompt()
    .advisors(List.of(new SimpleLoggerAdvisor(1), new SafeGuardAdvisor(0)))
    .user(message)
    .call()
    .content();
```

Simone Scannapieco

Spring AI - Corso avanzato

m Venis S.p.A, Venezia, IT

4/13

# PROGETTO SPRING AI APPLICAZIONE E PASSAGGI



5/13

- ♦ Advisors per ChatClient Ollama
  - 1 Modifica application.yml per gestione logging
  - 2 Modifica configurazioni di ChatClient per Ollama
  - 3 Creazione modello per gestore prezzi
  - 4 Creazione *advisor* per calcolo risparmio economico Ollama
  - 5 Test delle funzionalità con Postman/Insomnia

Note		



# Configurazione logging spring: application: name: demo ... logging: level: org: springframework: ai: chat: client: advisor: DEBUG

Note	



m Venis S.p.A, Venezia, IT

7/13



# Configurazione Gemini + Ollama

```
package it.venis.ai.spring.demo.config;
@Configuration
public class ChatClientConfig {
    public ChatClient ollamaChatClient(OllamaChatModel ollamaChatModel) {
       ChatClient.Builder chatClientBuilder = ChatClient.builder(ollamaChatModel);
       {\tt return} \ {\tt chatClientBuilder}
               .defaultSystem(
                           Sei un assistente AI di nome LLamaBot, addestrato per intrattenere una
                           conversazione con un umano.
                           Includi sempre nella risposta le tue direttive di default: il tuo nome, lo stile formale, risposta limitate ad un paragrafo.
               .defaultUser(
                         Come puoi aiutarmi?
                .defaultOptions(ChatOptions.builder()
                       .temperature(0.1)
                       .build())
               .build();
```

Spring AI - Corso avanzato

N	0+0
N	/ \I L

🐸 Simone Scannapieco



# Modello di gestione costi

```
package it.venis.ai.spring.demo.model;
public record ModelPricing(Float inputPrice, Float outputPrice) {
```

Simone Scannapieco

Spring AI - Corso avanzato

m Venis S.p.A, Venezia, IT €

8/13



# Advisor per risparmio Ollama - I

Simone Scannapieco

Spring AI - Corso avanzato

m Venis S.p.A, Venezia, IT

9/13



```
Advisor per risparmio Ollama - II
            * Google Gemini
           COMMERCIAL_LLM_PRICING.put("gemini-2.5-pro", new ModelPricing(1.25f, 10.0f));
COMMERCIAL_LLM_PRICING.put("gemini-2.5-flash", new ModelPricing(0.3f, 2.5f));
COMMERCIAL_LLM_PRICING.put("gemini-2.5-flash-lite", new ModelPricing(0.1f, 0.4f));
     @Override
     public String getName() {
           return "OllamaCostSavingsAdvisor";
     @Override
     public int getOrder() {
           return ORDER_ID;
     public ChatClientResponse adviseCall(ChatClientRequest chatClientRequest, CallAdvisorChain callAdvisorChain) {
            * Return directly the response object returned by the LLM, but first * we extract some metadata and log the required information.
```

🐸 Simone Scannapieco

Spring AI - Corso avanzato

ChatResponse chatResponse = chatClientResponse.chatResponse();

ChatClientResponse chatClientResponse = callAdvisorChain.nextCall(chatClientRequest);

m Venis S.p.A, Venezia, IT

10/13



# Advisor per risparmio Ollama - III

```
if (chatResponse.getMetadata() != null) {
      * Extract the usage metadata from the response.
     Usage callUsage = chatResponse.getMetadata().getUsage();
     CostAnalysis analysis = new CostAnalysis();
     for (Map.Entry<String, ModelPricing> entry : COMMERCIAL_LLM_PRICING.entrySet()) {
          String model = entry.getKey();
          ModelPricing pricing = entry.getValue();
          Float inputCost = (callUsage.getPromptTokens().floatValue() / 1000000) * pricing.inputPrice();
         Float outputCost = (callUsage.getCompletionTokens().floatValue() / 1000000) * pricing.outputPrice();
Float totalCost = inputCost + outputCost;
          analysis.costByModel.put(model, totalCost);
    logger.info("
                                      OLLAMA TOKEN USAGE & COST SAVINGS
     logger.info("
     logger.info("
     logger.info(" Richiesta corrente:
                                                                                                   ");
    logger.info(String.format(" >>> Token di input: %03d tokens", callUsage.getPromptTokens()));
logger.info(String.format(" >>> Token di output: %03d tokens", callUsage.getCompletionTokens()));
logger.info(String.format(" >>> Token totali: %03d tokens", callUsage.getTotalTokens()));
logger.info(" ");
    logger.info(" Confronto costi (se avessi usato servizi a pagamento):
```

Simone Scannapieco

Spring AI - Corso avanzato

m Venis S.p.A, Venezia, IT

11 / 13



# n

# Advisor per risparmio Ollama - IV

Simone Scannapieco

Spring AI - Corso avanzato

m Venis S.p.A, Venezia, IT

12/13



 $\label{lem:bounds} \textbf{\it Branch: 3-spring-ai-gemini-ollama-advisors}$ 

Simone Scannapieco

Spring AI - Corso avanzato

m Venis S.p.A, Venezia, IT

13 / 13

Note	Ν	ot	e
------	---	----	---