

# ICT Training Center







### **SPRING AI**

#### GENERATIVE ARTIFICIAL INTELLIGENCE CON JAVA

Simone Scannapieco

Corso avanzato per Venis S.p.A, Venezia, Italia

Novembre 2025



## PROGETTO SPRING AI APPLICAZIONE E PASSAGGI



- Multi configurazione Ollama + Gemma
  - Pull modello LLM ed embedder in Model Runner
  - 2 Test del raggiungimento del servizio chat/embed con Postman/Insomnia
  - Creazione profilo applicativo
  - Modifica proprietà applicativo
  - Test delle funzionalità con Postman/Insomnia

#### PROGETTO SPRING AL CONFIGURAZIONE OLLAMA + GEMMA



Cercare embedder su HuggingFace, con task NLP->Sentence similarity e Library->GGUF

#### Caricamento LLM in locale











Utilizzare Postman/Insomnia per chiamate di test

#### Test raggiungimento servizio *chat*

#### Test raggiungimento servizio e*mbedding*

# PROGETTO SPRING AI CONFIGURAZIONE OLLAMA + GEMMA



### Configurazione applicativo

```
spring:
...
profiles:
    active: rag-document-to-vector-store,docker-model-runner
...
```



#### File application-docker-model-runner.yml

```
spring:
ai:
openai:
api-key: pippoplutopaperino
base-url: http://localhost:12434/engines
chat:
completions-path: /llama.cpp/v1/chat/completions
options:
model: ai/gemma3
temperature: 0.2
embedding:
embedding:
embeddings-path: /llama.cpp/v1/embeddings
options:
model: hf.co/unsloth/embeddinggemma-300m-gguf # The model name must be taken from
# 'docker model list'
```

## CODICE BRANCH DI RIFERIMENTO



https://github.com/simonescannapieco/spring-ai-advanced-dgroove-venis-code.git

Branch: 10-spring-ai-gemma-ollama-docker-model-runner