



ICT Training Center



Il tuo partner per la Formazione e la Trasformazione digitale della tua azienda





SPRING AI

GENERATIVE ARTIFICIAL INTELLIGENCE CON JAVA

Simone Scannapieco

Corso avanzato per Venis S.p.A, Venezia, Italia

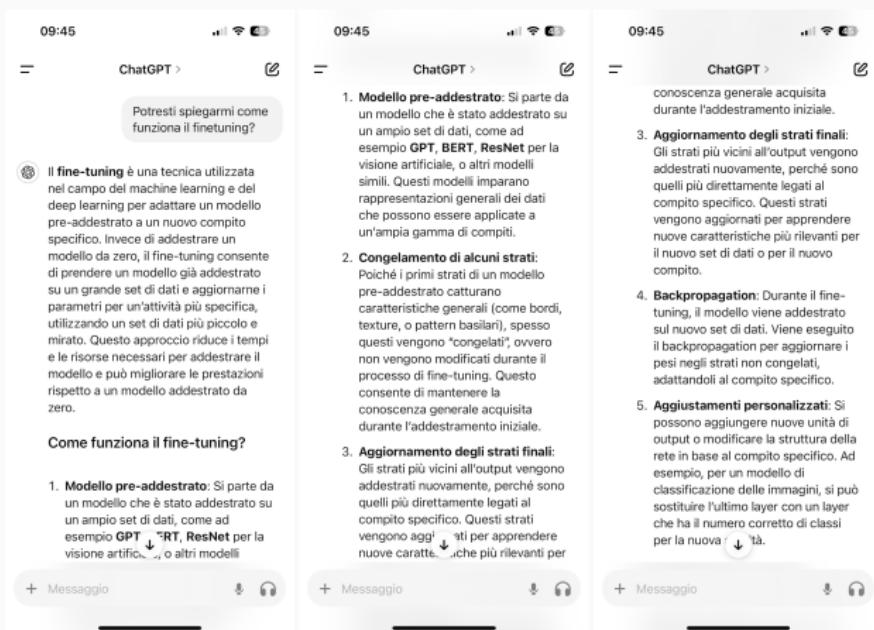
Novembre 2025

- ➡ Praticamente impossibile pre-addestrare un LLM (a meno che tu non sia Google, OpenAI, Mistral, Anthropic e pochissimi altri)
- ➡ Utilizzare un LLM per scopi personali è un conto, adottarli in un contesto *business* significa scontrarsi con problematiche di natura etica, legale ed economica
- ➡ Gli LLM saranno sempre più bravi a modellare la comprensione del linguaggio...

(?) ... ma come usarli per **task specifici**
o con conoscenza che a loro manca?

FINE-TUNING

DEFINIZIONE



09:45 ChatGPT > Potresti spiegarmi come funziona il finetuning?

09:45 ChatGPT >

- Modello pre-addestrato:** Si parte da un modello che è stato addestrato su un ampio set di dati, come ad esempio **GPT**, **BERT**, **ResNet** per la visione artificiale, o altri modelli simili. Questi modelli imparano rappresentazioni generali dei dati che possono essere applicate a un'ampia gamma di compiti.
- Congelamento di alcuni strati:** Poiché i primi strati di un modello pre-addestrato catturano caratteristiche generali (come bordi, texture, o pattern basiliari), spesso questi vengono "congelati", ovvero non vengono modificati durante il processo di fine-tuning. Questo consente di mantenere la conoscenza generale acquisita durante l'addestramento iniziale.
- Aggiornamento degli strati finali:** Gli strati più vicini all'output vengono addestrati nuovamente, perché sono quelli più direttamente legati al compito specifico. Questi strati vengono aggiornati per apprendere nuove caratteristiche più rilevanti per il nuovo set di dati o per il nuovo compito.
- Backpropagation:** Durante il fine-tuning, il modello viene addestrato sul nuovo set di dati. Viene eseguito il backpropagation per aggiornare i pesi negli strati non congelati, adattandoli al compito specifico.
- Aggiustamenti personalizzati:** Si possono aggiungere nuove unità di output o modificare la struttura della rete in base al compito specifico. Ad esempio, per un modello di classificazione delle immagini, si può sostituire l'ultimo layer con un layer che ha il numero corrente di classi per la nuova categoria.

+ Messaggio

+ Messaggio

+ Messaggio

⇒ *Full learning*

- Creare una architettura neurale da zero...
- ... oppure scegliere una architettura in letteratura (per i meno sadici)
- Addestramento da zero (a partire da pesi e *bias random*)

⇒ *Transfer learning*

- Sfruttare una rete neurale già addestrata su un altro insieme di dati di addestramento
- Modificare solo alcuni strati (solitamente gli ultimi) per addestrare la rete per i propri scopi

Computer Vision	Full learning	Transfer learning
Numero dati addestramento	$10^3\text{--}10^6$	10^2
Computazione	Intensiva (GPU)	Media (CPU-GPU)
Tempo di addestramento	Giorni-settimane	Ore-giorni
Accuratezza del modello	Alta	Variabile

- 👉 ChatGPT parla del *fine-tuning* per LLM come sinonimo di *transfer learning*
- 👉 Si parla di *full fine-tuning* quando nessuno strato viene congelato
- 👉 Diverse tecniche per quanto riguarda il “*transfer tuning*”...

- ➔ **Parameter-Efficient Fine-Tuning:** famiglia di tecniche per ridurre i parametri da addestrare
- ➔ **LoRA:** decomposizione a basso rango delle matrici di peso
 - ➔ Pro: efficiente, flessibile, prestazioni eccellenti
 - ➔ Contro: richiede scelta accurata di r e moduli target
- ➔ **Adapter Layers:** inserisce piccoli *layer* addestrabili tra *layer* esistenti
 - ➔ Pro: modularità, facilmente componibili
 - ➔ Contro: overhead di inferenza (layer aggiuntivi)
- ➔ **Prompt Tuning:** ottimizza solo *embedding* continui del *prompt*
 - ➔ Pro: estrema efficienza parametrica
 - ➔ Contro: prestazioni inferiori su modelli piccoli
- ➔ LoRA attualmente considerato il miglior compromesso efficienza/prestazioni



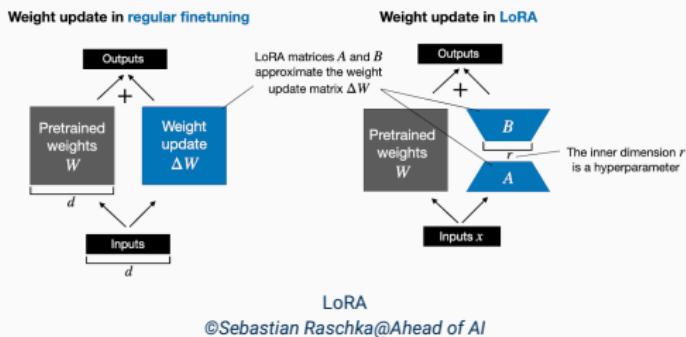
Edward Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu,

Yuanzhi Li, Shean Wang, Lu Wang, Weiqi Chen.

LoRA. Low-Rank Adaptation of Large Language Models. ArXiV, 2021.



- ➡ Variazione di PEFT
- ➡ Si riaddestrano solo un sottosinsieme ΔW di parametri esplicitamente selezionati (una sorta di *transfer learning*) . . .
- ➡ . . . mantenendo fissi tutti gli altri W
- ➡ Fissato un parametro r (rango), LoRA approssima ΔW come prodotto scalare di due matrici più piccole



Prodotto scalare

Il prodotto scalare di matrice $(n \times r) A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1r} \\ \vdots & \vdots & \vdots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nr} \end{bmatrix}$ e matrice $(r \times m)$

$B = \begin{bmatrix} b_{11} & b_{12} & \dots & b_{1m} \\ \vdots & \vdots & \vdots & \vdots \\ b_{r1} & b_{r2} & \dots & b_{rm} \end{bmatrix}$ é la matrice $(n \times m)$

$$A \cdot B = \begin{bmatrix} a_{11} * b_{11} + \dots + a_{1r} * b_{r1} & \dots & a_{11} * b_{1m} + \dots + a_{1r} * b_{rm} \\ \vdots & \vdots & \vdots \\ a_{n1} * b_{11} + \dots + a_{nr} * b_{r1} & \dots & a_{n1} * b_{1m} + \dots + a_{nr} * b_{rm} \end{bmatrix}$$

- ➔ In pratica, fissato r , LoRA computa A e B tale per cui $\Delta W = A \cdot B$
- ➔ Ma perché é così potente?!

Esempio LoRA

$$\Delta W = \begin{bmatrix} 5 & 1 & -1 & 3 & 4 \\ 15 & 3 & -3 & 9 & 12 \\ 35 & 7 & -7 & 21 & 28 \\ -20 & -4 & 4 & -12 & -16 \\ 10 & 2 & -2 & 6 & 8 \end{bmatrix} \xrightarrow{\text{LoRA}(r=1)} A = \begin{bmatrix} 1 \\ 3 \\ 7 \\ -4 \\ 2 \end{bmatrix}, B = [5 \quad 1 \quad -1 \quad 3 \quad 4]$$

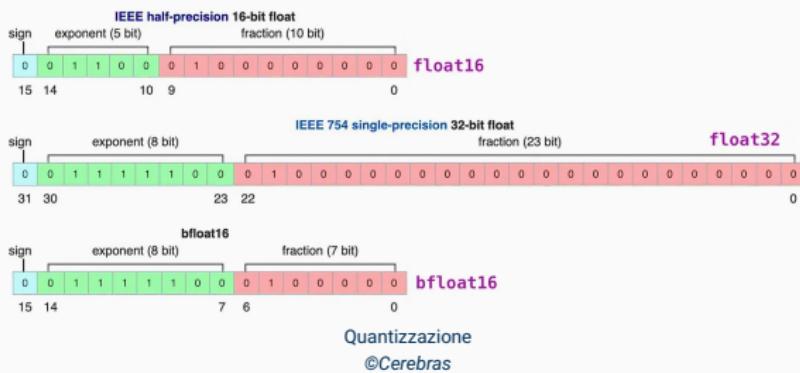
- ➔ Numero parametri da salvare?
 - ➔ ΔW : 25
 - ➔ A e B (totale): 10
 - ➔ Risparmio spazio: 40%
- ➔ La *backpropagation* opera direttamente sulle rappresentazioni di A e B !
- ⚠ Metodo di **approssimazione**, quindi a scapito della **accuracy** del modello

LoRA vs Full Fine-tuning

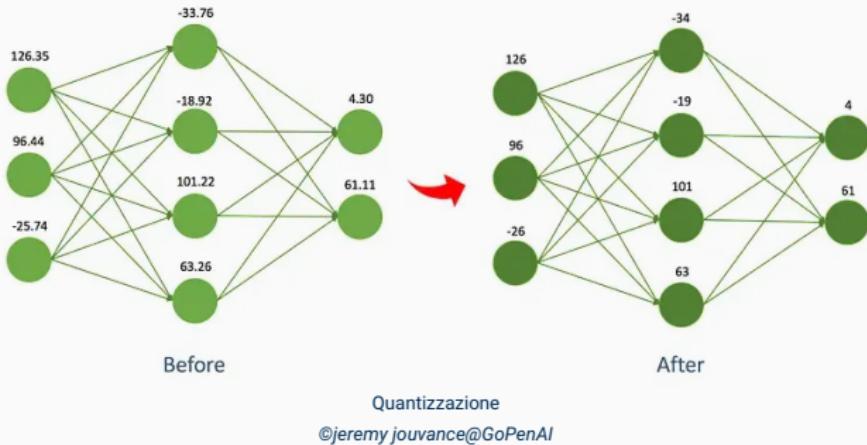
CONFRONTO PRATICO

Aspetto	Full Fine-tuning	LoRA
Parametri addestrabili	Tutti (~100%)	0.1–1% del totale
Memoria GPU richiesta	Molto alta (es. 80GB per 7B)	Ridotta (es. 16GB per 7B)
Tempo addestramento	Lungo	Significativamente ridotto
Accuratezza finale	Massima	Comparabile (95-99%)
Rischio overfitting	Alto con pochi dati	Basso
Storage adattatori	Modello completo (GBs)	Solo adattatori (MBs)
Multi-task	Richiede modelli separati	Adattatori intercambiabili

- ➊ Decidere la precisione dei parametri del modello (ovvero, quantizzandolo)



- ➊ Quantizzazione a **float16** e **bfloat16** usati maggiormente per addestramento
- ➋ **bfloat16** generalmente preferito a **float16**
- ➌ Addestramento a **float32** riservato alle *big companies*
- ➍ Quantizzazioni inferiori disponibili (**int8**, **int4**), ma consigliate per inferenza



- ➔ A favore del peso del modello in memoria e ai tempi di addestramento...
- ➔ ... a scapito dell'accuratezza in fase di inferenza

- ➡ Quantizzazione terminata il processo di addestramento (**Post Training Quantization – PTQ**)
- ➡ **GPTQ**: quantizzazione post-addestramento per GPU, ottimizzata per inferenza veloce
- ➡ **GGUF/GGML**: formato quantizzato per CPU e Metal (Apple Silicon), popolare per uso locale
- ➡ Quantizzazione durante l'addestramento (**Quantization-Aware Training – QAT**)
- ➡ **BitsAndBytes (bitsandbytes)**: libreria per quantizzazione dinamica 8-bit e 4-bit

Formato	Riduzione memoria	Uso principale	Accuratezza
int8	~50%	Inferenza	Alta
int4	~75%	Inferenza	Media-Alta
GPTQ	~75%	Inferenza (GPU)	Alta
GGUF	50-80%	Inferenza (CPU)	Variabile



Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, Luke Zettlemoyer.

QLoRA: Efficient Finetuning of Quantised LLMs.

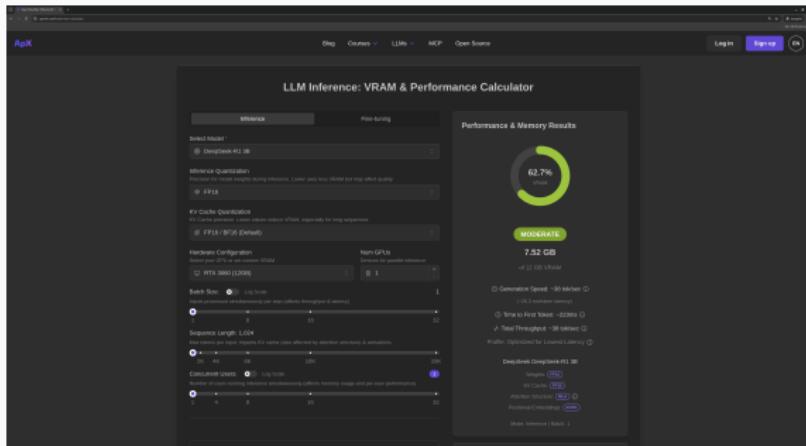
ArXiV, 2023.



- ➔ Decomposizione LoRA + Quantization...
- ➔ ... tutto qui.

- ➔ QLoRA introduce ottimizzazioni chiave per ridurre drasticamente l'uso di memoria
 - ➔ Congelamento e quantizzazione totale del modello originale a 4 bit
 - ➔ **4-bit NormalFloat (NF4)**: quantizzazione ottimizzata per distribuzioni normali dei pesi
 - ➔ **Paged Optimizers**: gestione della memoria simile alla memoria virtuale del SO
- ➔ Solo gli adattatori LoRA vengono addestrati in precisione maggiore (tipicamente bfloat16)
- ⚠ Riduzione tempi di addestramento e spazio richiesto rispetto a LoRA
 - ➔ *Fine-tuning* di modelli da 65B parametri su GPU consumer (24GB)

- ⚠️ Stima memoria GPU necessaria per *fine-tuning*?!
- 👉 **Full fine-tuning:** Memoria $\approx 4 \times \text{parametri} \times \text{bytes per parametro}$
- ⚠️ Fattore 4x: modello + gradienti + stati ottimizzatore
- 👉 **LoRA:** Memoria $\approx 2 \times n_{\text{params}} + n_{\text{LoRA_adapters}} \times \text{dim}_{\text{LoRA_adapters}}$, $\text{dim}_{\text{LoRA_adapters}} \approx 200MB$
- 👉 **QLoRA:** Memoria $\approx .5 \times n_{\text{params}} + n_{\text{LoRA_adapters}} \times \text{dim}_{\text{LoRA_adapters}}$, $\text{dim}_{\text{LoRA_adapters}} \approx 200MB$
- 👉 Batch size e lunghezza sequenza impattano significativamente
- ⚠️ Considerare anche memoria per attivazioni intermedie ($\approx 50\%$ aggiuntivo)



🔗 <https://apxml.com/tools/vram-calculator>

➡ Preparazione dataset

- ➡ Qualità > Quantità: meglio 1000 esempi di alta qualità che 10000 rumorosi
- ➡ Formattazione consistente: usare *template* uniformi per prompt e risposte
- ➡ Bilanciamento: evitare sbilanciamenti tra categorie o lunghezze

➡ Iperparametri addestramento

- ➡ *Learning rate*: tipicamente [5e-5, 1e-4] per *full*, [3e-4, 1e-3] per LoRA
- ➡ Poche epoche: 1-5 epoche solitamente sufficienti (rischio *overfitting*)

➡ Prevenzione *overfitting*

- ➡ *Early stopping*: monitorare *loss* su *validation set*
- ➡ *Dropout* e *weight decay* per regolarizzazione
- ➡ *Validation* regolare su esempi reali del dominio texttarget

⇒ Full fine-tuning

- ➔ Cambio drastico di dominio (es. da generale a medico/legale)
- ➔ Dataset molto grandi ($>100K$ esempi di alta qualità)
- ➔ Risorse computazionali abbondanti
- ➔ Massima accuratezza richiesta per il task

⇒ LoRA/QLoRA

- ➔ Adattamento stile, tono, formato *output*
- ➔ Comportamenti specifici o *task* strutturati
- ➔ Dataset 1K–100K esempi, risorse *hardware* limitate
- ➔ Necessità di gestire multipli adattatori per *task* diversi