



ICT Training Center

Il tuo partner per la Formazione e la Trasformazione digitale della tua azienda



SPRING AI

GENERATIVE ARTIFICIAL INTELLIGENCE CON JAVA


Simone Scannapieco

Corso avanzato per Venis S.p.A, Venezia, Italia

Novembre 2025

RETRIEVAL AUGMENTED GENERATION

- ➔ **Simple prompting:** utente costruisce il contesto manualmente
 - ⚠ LLM genera una risposta in base alla conoscenza su cui è stato addestrato (*knowledge cut-off*)
 - ⚠ Impensabile pre-addestrare LLM su qualunque sotto-dominio specifico
 - ⚠ Quando informazione contestuale non è sufficiente, LLM tende a generare risposte non veritiere (*hallucination*)
- ➔ **Prompt stuffing:** contesto utente arricchito dinamicamente (es. *chat memory*)
 - ⚠ Prompt potenzialmente eccessivi in grandezza
 - ⚠ Problematiche di *context window*
 - ⚠ Costi esorbitanti con LLM commerciali
 - ⚠ Tempi di risposta proibitivi con LLM *open source*



- ➔ Pre-addestramento costante per le LLM non è efficiente
- ➔ Come fare con **fattoidi** (es. cariche politiche, popolazione per stato, . . .)?!


RETRIEVAL AUGMENTED GENERATION

RIVOLUZIONE NEL MONDO DELL'ADDESTRAMENTO LLM



Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Kuttler, Mike Lewis, Wen-Tau Yin, Tim Rocktaschel, Sebastian Riedel, Douwe Kiela. *Retrieval-Augmented Generation of Knowledge-Intensive NLP Tasks*.

ArXiv, 2021.



11:43 4G

ChatGPT >

Spiegami brevemente cosa è RAG

 RAG (Retrieval-Augmented Generation) è una tecnica avanzata nell'ambito dell'intelligenza artificiale e del Natural Language Processing (NLP). Combina due approcci principali:

1. **Retrieval (Recupero):** Viene utilizzato un sistema di ricerca per estrarre informazioni pertinenti da una grande base di dati o documenti, che potrebbero essere rilevanti per una determinata query o richiesta.

2. **Generation (Generazione):** Dopo aver recuperato queste informazioni, viene utilizzato un modello di generazione di linguaggio naturale (come GPT) per sintetizzare e presentare una risposta ben strutturata basata sia sulle informazioni recuperate che sulle proprie capacità generative.

In pratica, RAG consente ai modelli di intelligenza artificiale di combinare il potere della ricerca documentale con la capacità di generare testi coerenti e dettagliati, risultando in risposte più accurate e informate, soprattutto in contesti dove è necessario un supporto fattuale preciso.

- ➔ Nuova frontiera del *prompt engineering*
- ➔ Riduce i costi di addestramento LLM
- ➔ Mantiene costantemente aggiornati i sistemi LLM
- ➔ Costi di integrazione contenuti


- 1 Utente fornisce il *prompt*
 - 2 Il sistema effettua una ricerca mirata su un *data source* di informazione documentale
 - 3 Il risultato della ricerca viene aggiunta al contesto del *prompt*
- ⚠ Ricerca di tipo **semantica**
 - ⚠ Solo il contesto rilevante alla richiesta aggiunto al *prompt* (a differenza di *chat memory*...)

- ➔ Basi di dati creati per CRUD di informazione **numerica multi-dimensionale**
- ➔ Ogni elemento nel DB è la rappresentazione numerica del suo significato (*embedding*)
 - ➔ Testi
 - ➔ Immagini
 - ➔ Video
 - ➔ Audio
 - ➔ ...
- ➔ Evoluzioni dei DB ottimizzati per ricerca su *keyword* (es. Elastic-Search)
 - ⚠ Non più limitati alla ricerca per parola esatta/simile!

- ➔ *Data source nativi*
 - ➔ Qdrant
 - ➔ ChromaDB
 - ➔ Neo4j
 - ➔ ...
- ➔ *Data source SQL/noSQL con interazione vector data storage*
 - ➔ MongoDB
 - ➔ PostgreSQL + pgvector
 - ➔ Redis + RediSearch
 - ➔ ElasticSearch
 - ➔ ...


WORKFLOW DEL PROCESSO RAG

APPROCCIO NON GENERATIVO



WORKFLOW DEL PROCESSO RAG

APPROCCIO GENERATIVO



RAG NON GENERATIVO: ESEMPIO

RICERCA SEMANTICA DI FILM E SERIE

