dgroove
Tecnologia emozionale.

ICT Training Center

Il tuo partner per la Formazione e la Trasformazione digitale della tua azienda

Note

Spring AI

Generative Artificial Intelligence con Java

Simone Scannapieco

Corso avanzato per Venis S.p.A, Venezia, Italia

Novembre 2025

Note

Tool Calling

Note

Tool calling
Descrizione

- *Design pattern* in AI (chiamata anche *function calling*)
- Tecnica di mitigazione della *knowledge cut-off*…
- …ma non solo
  - Ricerca di informazioni non presenti nella sua base di conoscenza
    - “Che tempo fa a Venezia?” ⇝ “Soleggiato con temperature massime sui 20°C”
    - ⚠ Quindi, differenza con RAG *web search*...?!
  - Logica più semplice e mirata per recupero delle informazioni
  - Messa in atto di ciò che comprende
    - “Prenota un biglietto” ⇝ 🎟
    - “Invia un’*email*” ⇝ ✉
    - “Fissa un appuntamento per martedì prossimo alle 18 in ufficio” ⇝ 📅
  - Primo passaggio nella transizione da LLM a ALM (Action Language Model)

Note

RAG	*Tool calling*
Leggere un manuale fai-da-te per risolverla da solo	Chiamare un idraulico per riparare una perdita
“In base a quello che mi hai chiesto e avendo letto alcuni documenti, ti spiego”	“In base a quello che mi hai chiesto, ecco come far agire il sistema con i mezzi a disposizione”
Si concentra sulla generazione delle risposte utilizzando contenuti recuperati	Esegue azioni dal vivo o recupera dati dal vivo
Recupera solo documenti e continua a generare la risposta	Richiede all’*app client* di eseguire il *tool*

Note

Tool calling
Workflow in Spring AI - Default

1. L'utente invia la richiesta al LLM attraverso `ChatClient/ChatModel` riferendo al LLM i *tool* a sua disposizione

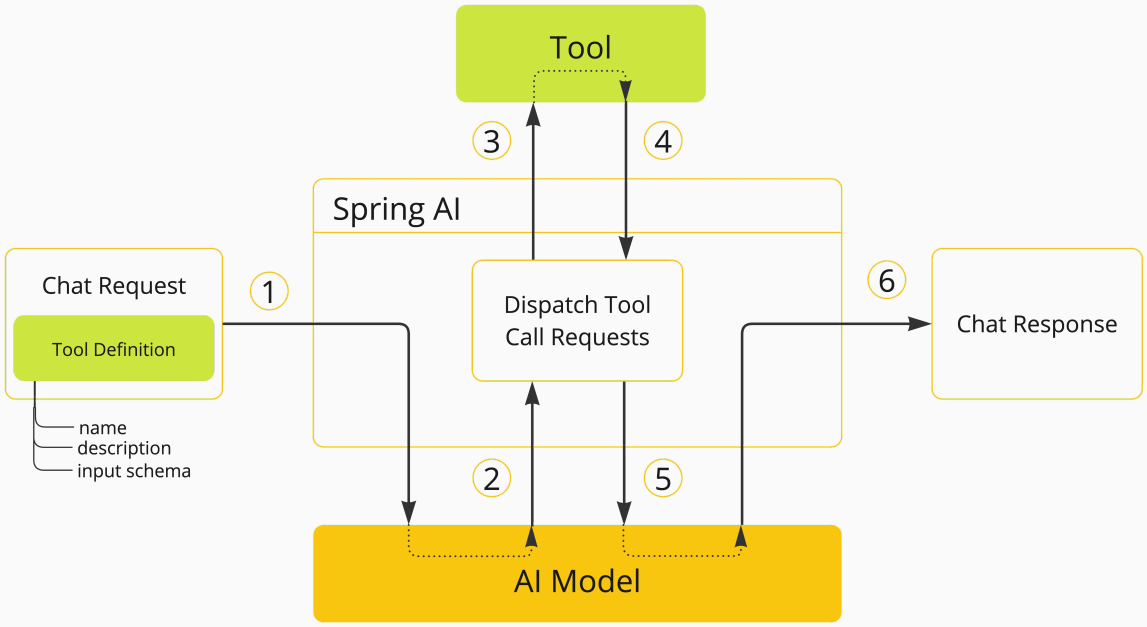

©Spring AI

Note

2. Se il LLM decide di chiamare un *tool*, invia una *response* con nome del *tool* e parametri istanziati, seguendo la schema definito per il *tool*

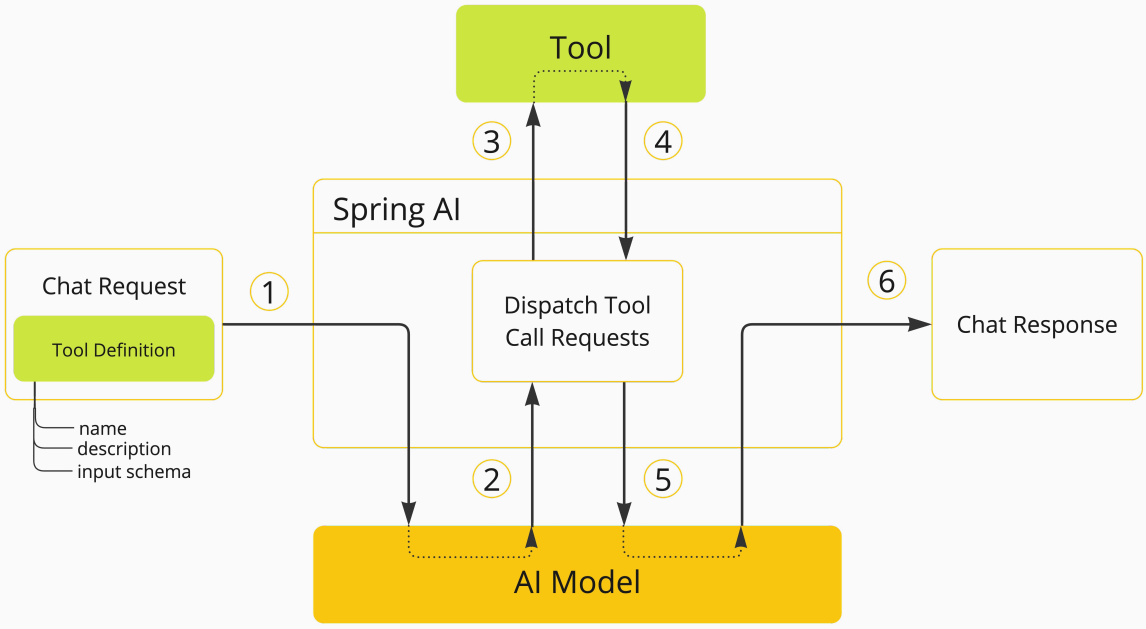

Note

3. L'applicativo inoltra all'effettiva implementazione del *tool* nel *container* Spring la richiesta con istanziazione dei parametri suggeriti dal LLM

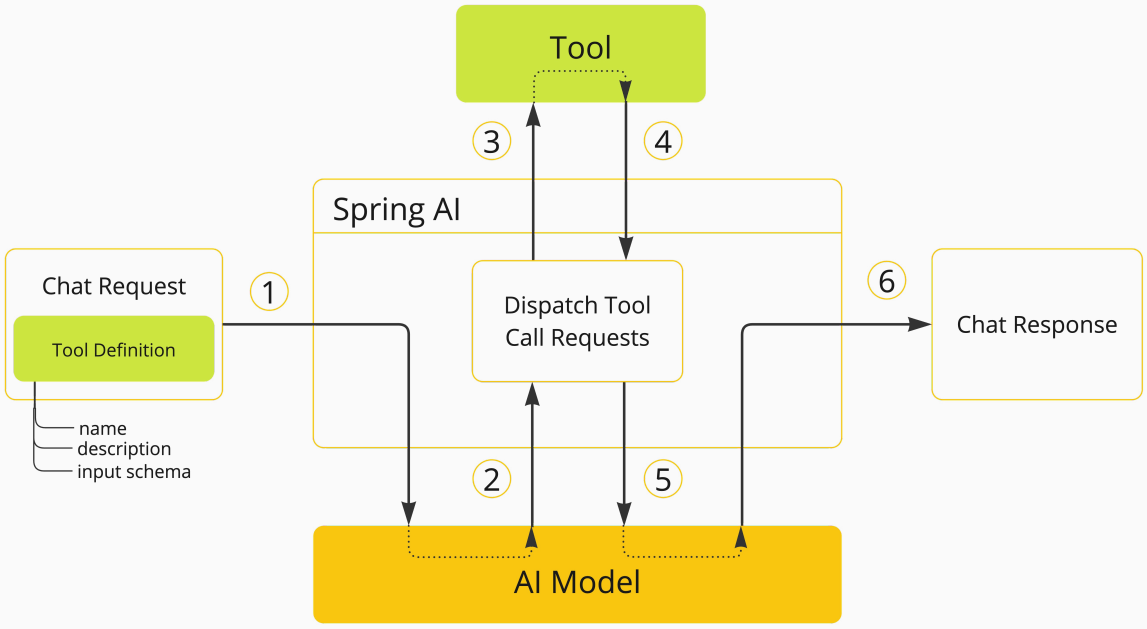

©Spring AI

Note

4. Il *tool* esegue la sua logica di implementazione con i parametri restituiti dal LLM e restituisce il risultato al *container* Spring

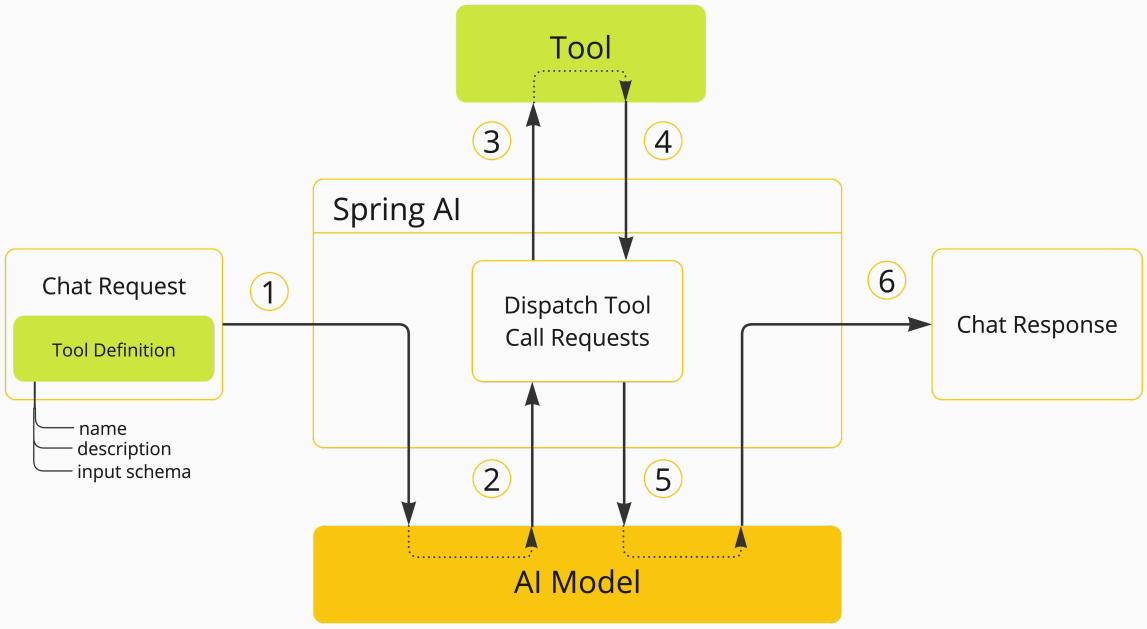

©Spring AI

Note

5 Il sistema invoca nuovamente il LLM con la richiesta utente precedente ma ulteriormente contestualizzata dall'*output* del *tool*

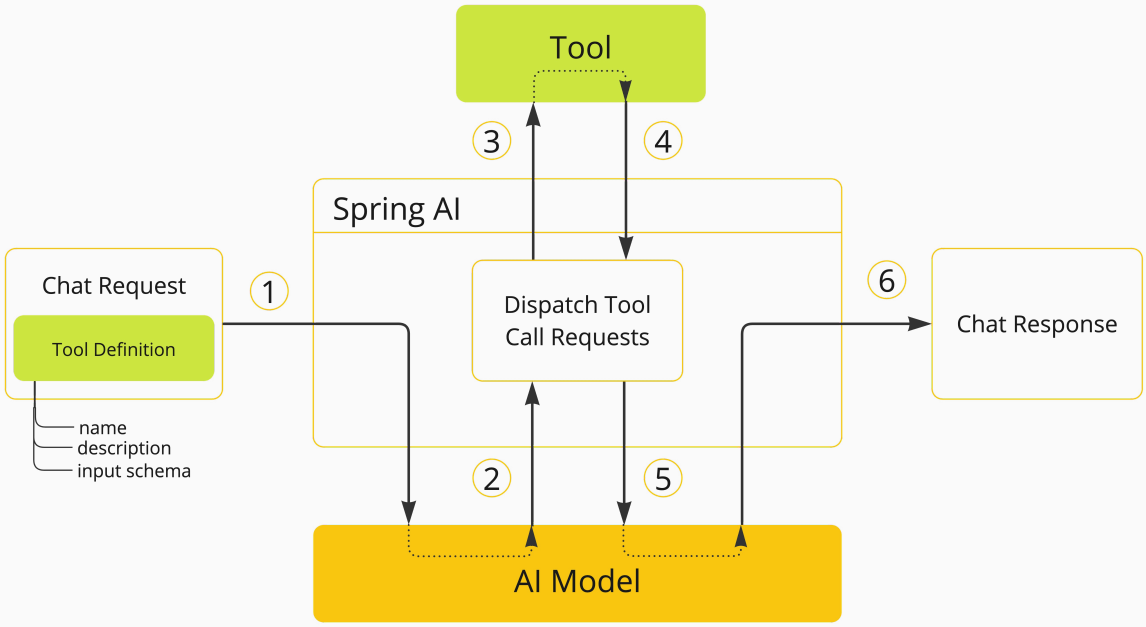

©Spring AI

Note

6 Il LLM restituisce la risposta finale al `ChatClient/ChatModel` sfruttando generazione di testo e contesto

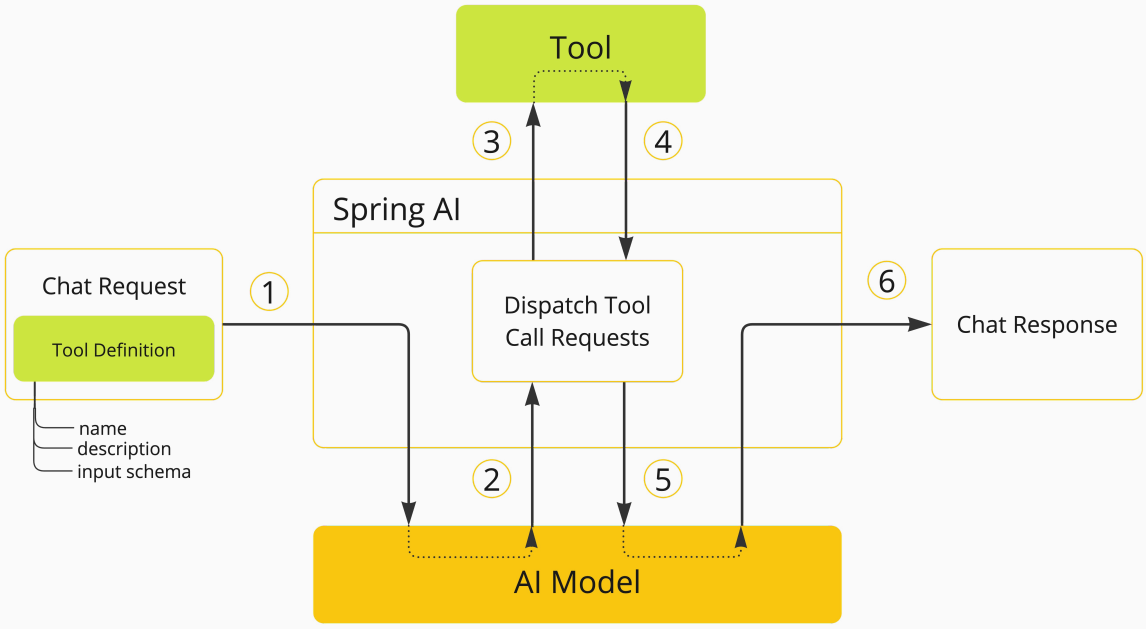

©Spring AI

Note

5 Il sistema restituisce il risultato del *tool* direttamente a `ChatClient/ChatModel` senza interrogare nuovamente il LLM

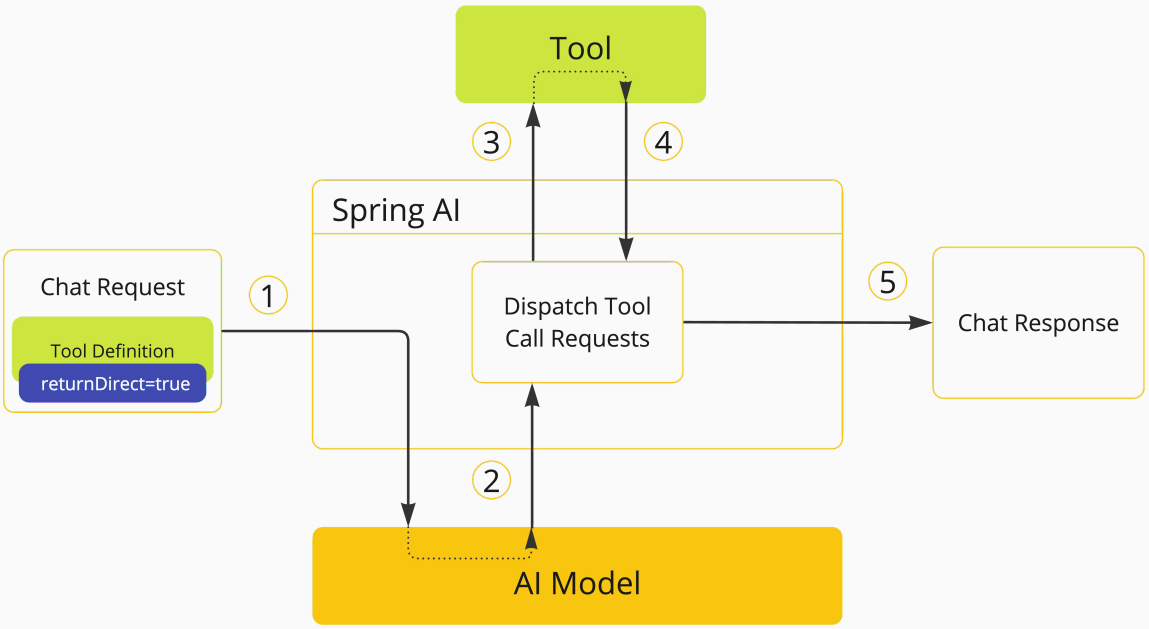

Note

- Metodologie
  - Dichiarativa
  - Programmatica
- Paradigmi
  - *Method As Tool* (MAT)
  - *Function As Tool* (FAT)

Note

Tool Calling

Method as tool

Note

Classe di definizione dei *tool*

```
@Component
public class TimeTools {

    @Tool(name="getCurrentLocalTime",
          description="Ottieni l'ora corrente nel fuso orario dell'utente.")
    String getCurrentLocalTime() {
        ...
    }

    @Tool(name="getCurrentTime",
          description="Ottieni l'ora corrente nel fuso orario specificato.",
          returnDirect=true)
    public String getCurrentTime(@ToolParam(description = "Valore che rappresenta il fuso orario.") String timeZone) {
            ...
        }
}
```

- Istanziati come `@Component`
- Ogni metodo a disposizione del LLM come *tool* deve essere annotato come `@Tool`
  - se `name` non specificato, Spring AI popola il parametro con il nome del metodo
  - ⚠ `name` come identificativo univoco per Spring AI
  - `description` fornisce il contesto al LLM per determinare se utilizzare il *tool* in base alla richiesta utente!
  - `@ToolParam` fornisce ulteriore contesto al LLM per iniettare parametri al metodo
  - `returnDirect` per sovrascrivere il comportamento di *default* se necessario

Note

Classe di definizione dei *tool*

```
@Component
public class TimeTools {

    @Tool(name="getCurrentLocalTime",
          description="Ottieni l'ora corrente nel fuso orario dell'utente.")
    String getCurrentLocalTime() {
        ...
    }

    @Tool(name="getCurrentTime",
          description="Ottieni l'ora corrente nel fuso orario specificato.",
          returnDirect=true)
    public String getCurrentTime(@ToolParam(description = "Valore che rappresenta il fuso orario.") String timeZone) {
            ...
        }
}
```

"D: Che ore sono a New York?"
>_ (thinking) — Scansiono i tool a disposizione... —
>_ (thinking) — Vedo che ho dei tool che gestiscono il recupero dell'ora... —
>_ (thinking) — Il primo tool è relativo alla posizione dell'utente... —
>_ (thinking) — Il secondo tool è più astratto e determina la posizione attraverso parametrizzazione del fuso orario... —
>_ (thinking) — ...Il fuso orario di New York è America/New York... —
>_ "R: Utilizza il tool `getCurrentTime('America/New York')`."

Processo di *method as tool*

Note

Tool-aware `ChatClient` - approccio statico

```
@Bean
public ChatClient ollamaTimeToolsChatClient(OllamaChatModel ollamaChatModel, TimeTools timeTools) {

    ChatClient.Builder chatClientBuilder = ChatClient.builder(ollamaChatModel);

    return chatClientBuilder
        .defaultTools(timeTools)
        ...
        .build();

    }
```

Tool-aware `ChatClient` - approccio dinamico

```
@Override
public Answer getOllamaTimeToolsLocalTimeAnswer(QuestionRequest request) {

    return new Answer(this.ollamaTimeToolsChatClient
        .prompt()
        .tools(timeTools)
        ...
        .call()
        .content());

}
```


Note

Classe di definizione dei *tool*

```
public class TimeTools {

    String getCurrentLocalTime() {
        ...
    }

    public String getCurrentTime(
        @ToolParam(description = "Valore che rappresenta il fuso orario.") String timeZone) {
        ...
    }

}
```

- `@ToolParam` permesso in approccio sia dichiarativo che programmatico

Note

Utilizzo approccio *method-tool callback*

```java
import java.lang.reflect.Method;

Method method = MethodToolCallbackReflectionUtils.findMethod(TimeTools.class, "getCurrentLocalTime");
ToolCallback toolCallback = MethodToolCallback.builder()
    .toolDefinition(ToolDefinitions.builder(method)
            .name("getCurrentLocalTime")
            .description("Ottieni l'ora corrente nel fuso orario dell'utente.")
            .build())
    .toolMethod(method)
    .toolObject(new TimeTools())
    .toolMetadata(ToolMetadata.builder()
        .returnDirect(true)
        .build())
    .build();
```

- Il sistema usa *reflection* per linkare il metodo
- Costruito un `ToolCallback` che definisce la logica di utilizzo del *tool*
  - `ToolDefinitions.Builder` permette di definire nome, descrizione e schema del *tool*
  - `ToolMetadata.Builder` responsabile della definizione strategia *default vs direct*
- Definizione `ToolCallback` *under-the-hood* anche con approccio dichiarativo

Note

Tool-aware `ChatClient` - approccio statico

```
@Bean
public ChatClient ollamaTimeToolsChatClient(OllamaChatModel ollamaChatModel) {

    ChatClient.Builder chatClientBuilder = ChatClient.builder(ollamaChatModel);

    return chatClientBuilder
        .defaultToolCallbacks(toolCallback)
        ...
        .build();

    }
```

Tool-aware `ChatClient` - approccio dinamico

```
@Override
public Answer getOllamaTimeToolsLocalTimeAnswer(QuestionRequest request) {

    return new Answer(this.ollamaTimeToolsChatClient
        .prompt()
        .toolCallbacks(toolCallback)
        ...
        .call()
        .content());

}
```


Note

- Restrizioni di tipo per parametri e valori di ritorno
- Tipi non supportati
  - **Tipi Optional** - `Optional<T>` non è compatibile
  - **Costrutti asincroni** - `CompletableFuture`, `Future`
  - **Tipi reattivi** - `Flow`, `Mono`, `Flux`
  - **Tipi funzionali** - `Function`, `Supplier`, `Consumer`
- I tipi funzionali sono supportati attraverso l'approccio function-based dedicato

Note

Tool Calling

Function as tool

Note

Classe di definizione dei *tool*

```
@Configuration(proxyBeanMethods = false)
class WeatherTools {

    public static final String GET_TEMP_IN_LOCATION_FUNCTION_NAME = "getTemperatureInLocation";

        @Bean(GET_TEMP_IN_LOCATION_FUNCTION_NAME)
        @Description("Ottieni la temperatura corrente nella località specificata.")
        Function<WeatherRequest, TemperatureResponse> currentTemperature() {
                return new TemperatureService();
        }

}

public enum Unit { C, F }

public record WeatherRequest(
    @ToolParam(description = "Il nome di una città o di una nazione.") String location, Unit unit) {}

public record TemperatureResponse(double temp, Unit unit) {}
```

- **Tipi funzionali supportati:** `Function<I,O>`, `Supplier<O>`, `Consumer<I>`, `BiFunction<I1,I2,O>`
- Ciascun funzionale disponibile come *tool* attraverso definizione `@Bean`
  - Definire nome come costante esportabile per mancanza di garanzia *type safety*
- `@Description` come `description` di MAT
- `@ToolParam` con medesima logica di MAT

Note

Tool-aware `ChatClient` - approccio statico

```
@Bean
public ChatClient ollamaWeatherToolsChatClient(OllamaChatModel ollamaChatModel) {

    ChatClient.Builder chatClientBuilder = ChatClient.builder(ollamaChatModel);

    return chatClientBuilder
        .defaultToolNames(WeatherTools.GET_TEMP_IN_LOCATION_FUNCTION_NAME)
        ...
        .build();
}
```

Tool-aware `ChatClient` - approccio dinamico

```
@Override
public TemperatureResponse getOllamaTemperatureToolAnswer(@RequestBody WeatherRequest request) {

    return this.ollamaWeatherToolsChatClient
        .toolNames(WeatherTools.GET_TEMP_IN_LOCATION_FUNCTION_NAME)
        ...
        .call()
        .content();

}
```


Note

Classe di definizione dei funzionali

```
public class TemperatureService implements Function<WeatherRequest, TemperatureResponse> {

    public WeatherResponse apply(WeatherRequest request) {
        ...
    }

}

public enum Unit { C, F }

public record WeatherRequest(
    @ToolParam(description = "Il nome di una città o di una nazione.") String location, Unit unit) {}

public record TemperatureResponse(double temp, Unit unit) {}
```

- Richiesta sola la logica pertinente al funzionale scelto (es. `apply` per `Function`)

Note

Utilizzo approccio *function-tool callback*

```
public static final String GET_TEMP_IN_LOCATION_FUNCTION_NAME = "getTemperatureInLocation";

ToolCallback toolCallback = FunctionToolCallback
    .builder(GET_TEMP_IN_LOCATION_FUNCTION_NAME, new TemperatureService())
    .description("Ottieni la temperatura corrente nella località specificata.")
    .inputType(WeatherRequest.class)
    .toolMetadata(ToolMetadata.builder()
        .returnDirect(true)
        .build())
    .build();
```

- `FunctionToolCallback.Builder` linka un identificativo testuale ad una istanza di una nuova *function tool*
- Costruito un `ToolCallback` che definisce la logica di utilizzo del *tool*
  - `ToolDefinitions.Builder` permette di definire nome, descrizione e schema del *tool*
  - `ToolMetadata.Builder` responsabile della definizione strategia *default vs direct*
- Definizione `ToolCallback` *under-the-hood* anche con approccio dichiarativo

Note

Tool-aware `ChatClient` - approccio statico

```
@Bean
public ChatClient ollamaWeatherToolsChatClient(OllamaChatModel ollamaChatModel) {

    ChatClient.Builder chatClientBuilder = ChatClient.builder(ollamaChatModel);

    return chatClientBuilder
        .defaultToolCallbacks(toolCallBack)
        ...
        .build();
    }
```

Tool-aware `ChatClient` - approccio dinamico

```
@Override
public TemperatureResponse getOllamaTemperatureToolAnswer(@RequestBody WeatherRequest request) {

    return this.ollamaWeatherToolsChatClient
        .toolCallBacks(toolCallback)
        ...
        .call()
        .content();

}
```


Note

⚠ **Limitazioni** (vincoli di risoluzione dei tipi a *runtime*):

- Tipi primitivi
- `Optional`
- Collezioni (`List`, `Map`, `Array`, `Set`)
- Tipi asincroni e reattivi

Note